

6.3 最大似然估计 (MLE: Maximum Likelihood Estimation)

例 6.7 设鱼塘养了一塘鱼, 为了估计鱼的数量, 先一网打上 500 尾鱼, 在尾上涂以红色 (称其为红尾鱼), 然后放回鱼塘, 几天后, 再打上一网鱼, 在网中的 400 尾鱼中发现有 60 尾红尾鱼. 试估计该鱼塘中鱼的数量.

- 假定两次捕捞均是**随机的**, 且两次捕捞期间鱼的**数量不变**
- 设 **N** 为鱼塘中鱼的数量, **k** 为第二网中红尾鱼的数量, **$p_k(N)$** 为第二网中恰好有 **k** 尾红尾鱼的概率 (超几何分布)

$$p_k(N) = \frac{\binom{N-500}{400-k} \binom{500}{k}}{\binom{N}{400}}.$$




图 6.1: $p_{60}(N)$ 随 N 变化的取值

受此启发，引入似然函数的定义

定义6.1 似然函数

设样本 $\mathbf{X} = (X_1, X_2, \dots, X_n)$ 有联合概率密度函数或联合概率质量函数

$$f(\mathbf{x}; \boldsymbol{\theta}) = f(\mathbf{x}; \theta_1, \theta_2, \dots, \theta_k)$$

这里参数 $\boldsymbol{\theta} = (\theta_1, \theta_2, \dots, \theta_k) \in \Theta$, $\mathbf{x} = (x_1, x_2, \dots, x_n)$ 为样本 $\mathbf{X}$ 的一个样本值. 当固定 $\mathbf{x}$ 时把 $f(\mathbf{x}; \boldsymbol{\theta})$ 看成为 $\boldsymbol{\theta}$ 的函数, 称为似然函数 (likelihood function), 常记为 $L(\mathbf{x}; \boldsymbol{\theta})$ 或 $L(\boldsymbol{\theta})$.

- 似然函数 $L(\theta; \mathbf{x})$ 可以理解为若 $L(\theta; \mathbf{x}) = f(\mathbf{x}; \theta) > L(\theta; \mathbf{y}) = f(\mathbf{y}; \theta)$, 则在观测时出现点 $\mathbf{x}$ 的可能性要大一点
- 用似然函数最大的那个点 $\theta^* = (\theta_1^*, \dots, \theta_k^*)$ 作为估计值, 即
$$L(\theta_1^*, \dots, \theta_k^*; x_1, \dots, x_n) = \max_{(\theta_1, \dots, \theta_k) \in \Theta} L(\theta_1, \dots, \theta_k; x_1, \dots, x_n);$$
- 这样的估计称为“最大似然估计”或者极大似然估计(Maximum Likelihood Estimate, MLE)
- $g(\theta_1^*, \dots, \theta_k^*)$ 为 $g(\theta_1, \dots, \theta_k)$ 的最大似然估计

求解似然函数最大值常见情况

- 样本是简单随机样本的情况下，似然函数： $L(\theta) = \prod_{i=1}^n f_{\theta}(x_i)$
对数似然函数： $l(\theta) = \ln L(\theta)$ （处理更方便）
似然函数 $L(\theta)$ 达到最大 $\Leftrightarrow$ 对数似然函数 $l(\theta)$ 达到最大
- 如果似然函数 $L(\theta)$ 对 θ 是严格单调的，则似然函数的最大值在边界处达到，从而得到最大似然估计
- 如果非单调且对变量 $\theta = (\theta_1, \dots, \theta_k)$ 可微，则可通过求解下列方程得到驻点

$$\frac{\partial l(\theta)}{\partial \theta_i} = 0 \quad (\text{或者} \frac{\partial L(\theta)}{\partial \theta_i} = 0) \quad i = 1, \dots, k$$

若该方程组在 $(\theta_1, \dots, \theta_k)$ 定义域内有解，进一步验证是否为最大值点

- 似然函数的最大值点可能会在边界上达到，所以要和边界值作比较.
- 当似然函数不可导时，要用定义来求出最大似然估计.
- 最大似然估计量也是统计量，也有二重性，所以最大似然估计量 $\hat{\theta}_L(X_1, \dots, X_n)$ 是统计量，这方便于研究其概率性质；最大似然估计值 $\hat{\theta}_L(x_1, \dots, x_n)$ 是代入具体样本值后得到的具体数.
- 在没有歧义的情况下，我们用最大似然估计来统指参数的最大似然估计量或估计值.

例 6.8 设 $(x_1, \dots, x_n)$ 是从正态总体 $N(\mu, \sigma^2)$ 中抽取的一个样本, 求 (μ, σ^2) 的最大似然估计.

例 6.10 设 $(x_1, \dots, x_n)$ 是从均匀分布总体 $U(0, \theta)$ 中抽取的一个样本, 求最大似然估计 $\hat{\theta}_L$.

例 6.11 设 $(x_1, x_2, \cdots, x_n)$ 为来自均匀分布总体 $U\left(\theta - \frac{1}{2}, \theta + \frac{1}{2}\right)$ 的一组样本, $\theta > 0$ 为参数, 求参数 θ 的最大似然估计.

6.4 优良性准则

- 我们看到对同一个参数，有多个不同的估计量，因此，评选不同估计量的优劣性是需要考虑的——优良性准则。

✓ 无偏性

✓ 有效性

✓ 无偏性+有效性 $\implies$ 最小方差无偏估计

6.4.1 点估计的无偏性

定义 6.2 偏差与无偏性

设 $\hat{g}(X_1, \dots, X_n)$ 是 $g(\theta_1, \dots, \theta_k)$ 的一个估计量, 则称

$$\mathbb{E}_{\theta} \hat{g}(X_1, \dots, X_n) - g(\theta_1, \dots, \theta_k)$$

为估计量 $\hat{g}$ 的偏差. 如果对任一可能的 $(\theta_1, \dots, \theta_k) \in \Theta$, 都有

$$\mathbb{E}_{\theta_1, \dots, \theta_k} \hat{g}(X_1, \dots, X_n) = g(\theta_1, \dots, \theta_k), \quad (6.5)$$

则称 $\hat{g}$ 是 $g(\theta_1, \dots, \theta_k)$ 的一个无偏估计量.



- $\mathbb{E}_{\theta}$, $\mathbb{E}_{\theta_1, \dots, \theta_k}$ 是指期望在 **给定** $\theta = (\theta_1, \dots, \theta_k)$ 下计算的.
- 参数 $\theta \in \Theta \subset \mathbb{R}^k$, 无偏性要求 (6.5) 对所有的 $\theta \in \Theta$ **都成立**.

例 6.15 设总体分布的方差为 σ^2 , 证明样本方差是 σ^2 的无偏估计.

(样本量为 n , 总体均值为 μ .)

- 例6. 15说明矩估计 m_2 **不是** 方差 σ^2 的无偏估计
- 从无偏性标准看, 矩估计 **有时候** 不是一个很好的估计
- 相比于最大似然估计, 矩估计 **不需要知道** 总体的分布, 更便于使用
- 用样本标准差 S 来估计总体标准差 σ , 这也 **不是无偏估计**, 因为

$$\sigma^2 = E(S^2) = \text{Var}(S) + [E(S)]^2 \geq [E(S)]^2, \quad E(S) \leq \sigma.$$

例 6.16 设总体分布服从 $U(0, \theta)$, 证明 θ 的最大似然估计 $\hat{\theta}_L = X_{(n)}$ 不是 θ 的无偏估计.

注 设 $\hat{\theta}(X_1, \dots, X_n)$ 是 θ 的一个点估计, 如果

$$\lim_{n \rightarrow \infty} \mathbb{E} \hat{\theta}(X_1, \dots, X_n) = \theta, \quad \forall \theta \in \Theta,$$

则称 $\hat{\theta}(X_1, \dots, X_n)$ 是 θ 的一个渐近无偏估计.

例 6.17 设样本 $X \sim B(N, p)$, N 已知而 p 未知. 令 $g(p) = 1/p$, 则参数 $g(p)$ 的无偏估计不存在.

无偏估计不一定存在

例 6.14 设总体分布的期望为 μ , 由样本可以构造两个估计量: $\hat{\theta}_1 = \bar{X}$, $\hat{\theta}_2 = \sum_{i=1}^n \omega_i X_i$, 其中 $\omega_i, i = 1, \dots, n$ 为一组权. 问两个估计量是否为无偏估计?

无偏估计不唯一

6.4.2 最小方差无偏估计

- 直观上我们希望一个优良的估计量 偏差要小，波动也不能太大.
- 用均方误差(误差平方的平均)来衡量:

$$MSE_{\theta}(\hat{\theta}) = \mathbb{E}_{\theta}[\hat{\theta}(X_1, \dots, X_n) - \theta]^2$$

均方误差越小越好.

- 均方误差由两部分组成: $MSE_{\theta}(\hat{\theta}) = \text{Var}_{\theta}(\hat{\theta}) + [\mathbb{E}_{\theta}(\hat{\theta} - \theta)]^2$

第一部分衡量估计量的波动，第二部分衡量偏差，显然无偏估计有如下性质:

$$MSE_{\theta}(\hat{\theta}) = \text{Var}_{\theta}(\hat{\theta})$$

有效性

定义 6.3 有效性

设 $\hat{\theta}_1, \hat{\theta}_2$ 都是总体参数 θ 的无偏估计, 方差存在, 若

$$\text{Var}_{\theta}(\hat{\theta}_1) \leq \text{Var}_{\theta}(\hat{\theta}_2), \forall \theta \in \Theta \quad (6.6)$$

且至少存在一个 θ , 使上式不等号成立, 则称 $\hat{\theta}_1$ 比 $\hat{\theta}_2$ 更有效.



例 6.18 设总体分布的均值为 μ , 方差为 σ^2 . 现在用 $\hat{\theta}_1 = \bar{X}$ 和 $\hat{\theta}_2 = \sum_{i=1}^n \omega_i X_i$ 来估计 μ , 哪个更有效? 其中 $\sum_{i=1}^n \omega_i = 1, \omega_i \geq 0$.

例 6.19 设总体分布服从 $U(0, \theta)$, 试比较 θ 的矩估计 $\hat{\theta}_M = 2\bar{X}$ 和修正的最大似然估计 $\hat{\theta}_L = ((n+1)/n)X_{(n)}$ 的有效性.

最小方差无偏估计(MVUE)

是否存在这样一个无偏估计，它在所有无偏估计中具有最小的方差？

定义 6.4 最小方差无偏估计

设 $\hat{\theta}$ 是 $g(\theta)$ 的一个无偏估计, 若对 $g(\theta)$ 的任一无偏估计 $\hat{\theta}_1$, 都有

$$\text{Var}_{\theta}(\hat{\theta}) \leq \text{Var}_{\theta}(\hat{\theta}_1), \quad \forall \theta \in \Theta,$$

则称 $\hat{\theta}$ 是 $g(\theta)$ 的一个最小方差无偏估计(Minimum Variance Unbiased Estimate, 简称 MVUE)



6.4.3 克拉默-拉奥方差下界

命题 6.1 克拉默-拉奥方差下界

对 $g(\theta)$ 的任一无偏估计 $\hat{g}(\mathbf{X})$, 在正则条件下有

$$\text{Var}_{\theta}(\hat{g}(\mathbf{X})) \geq (g'(\theta))^2 [nI(\theta)]^{-1}. \quad (6.8)$$

这就是克拉默-拉奥方差下界.



令

$$S(\mathbf{X}, \theta) = \frac{\partial \ln f(\mathbf{X}|\theta)}{\partial \theta} = \sum_{i=1}^n \frac{\partial \ln f(X_i, \theta)}{\partial \theta},$$

其中 $f(\mathbf{x}|\theta) = \prod_{i=1}^n f(x_i, \theta)$ 为样本的联合密度.

$$\mathbb{E}_{\theta} S(\mathbf{X}, \theta) = 0,$$

$$\text{Var}_{\theta}(S(\mathbf{X}, \theta)) = n \int_{-\infty}^{\infty} \left[\frac{\partial f(x, \theta)}{\partial \theta} / f(x, \theta) \right]^2 f(x, \theta) dx \equiv nI(\theta) < \infty,$$

- 利用柯西-施瓦茨不等式，我们有

$$\text{Cov}^2(\hat{g}(\mathbf{X}), S(\mathbf{X}, \theta)) \leq \text{Var}(S(\mathbf{X}, \theta)) \cdot \text{Var}(\hat{g}(\mathbf{X})).$$

- 若无偏估计达到了克拉默-拉奥方差下界，则为MVUE.
- $I(\theta) = \mathbb{E}(\partial \ln f(X, \theta) / \partial \theta)^2$ 称为费歇尔 (Fisher) 信息函数

$I(\theta)$ 表达了样本量为1的样本中关于参数 θ 信息量的大小，而 $nI(\theta)$ 则表示了样本量为 n 的样本中关于 θ 信息量的大小.

$I(\theta)$ 越大, 方差下界越小, 意味参数 θ 越容易被估计准确, 样本量 n 越大, 参数被准确估计的概率越大.

例 6.22 设 $(X_1, \dots, X_n)$ 是从总体 $N(\mu, \sigma^2)$ 中抽取的一个样本, 其中 σ^2 已知. 对 μ 作点估计.

例 6.23 设总体为指数分布 $Exp(\lambda)$, 问 λ^{-1} 的无偏估计 $\bar{X}$ 是否为 MVUE?

6.5 点估计的大样本理论

- 当样本量趋向于无穷时点估计量的性质称为大样本性质，估计量在样本量固定时的性质称为小样本性质.
- 关于估计量或一般统计量的大样本性质的讨论构成了数理统计学的一个非常重要的部分，称为大样本统计理论.
- 大样本理论直到今天依然是统计研究的核心工作之一.

定义 6.5 相合性

设 $\hat{\theta}(X_1, \dots, X_n)$ 是参数 θ 的一个点估计, 如果样本量 $n \rightarrow \infty$ 时有

$$\hat{\theta}(X_1, \dots, X_n) \xrightarrow{P} \theta, \quad (6.9)$$

则称 $\hat{\theta}(X_1, \dots, X_n)$ 是 θ 的一个 (弱) 相合估计量 (consistent estimator).



- 直观上, 相合性就是当样本量趋于无穷时, 估计量依概率收敛于参数 θ , 即只能在 θ 附近作越来越小的摆动, 这称为相合性, 也称为一致性.
- 相合性是对一个估计量的基本要求.

例 6.26 证明 $m_2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$ 是总体方差 σ^2 的相合估计

例 6.27 (例6.10续) 设总体分布服从 $U(0, \theta)$, 证明 θ 的最大似然估计 $\hat{\theta}_L = X_{(n)}$ 是 θ 的相合估计.

- 可以证明, 矩估计是总体矩的相合估计. 一般而言, 最大似然估计也是待估参数的相合估计.

- 点估计的大样本性质中另一个重要的准则是其分布极限的特点, 称为渐近正态性

定义 6.6 渐近正态性

设 $\hat{\theta}(X_1, \dots, X_n)$ 是参数 θ 的一个点估计, 设它的方差存在, 记

$$\text{Var}_{\theta}[\hat{\theta}(X_1, \dots, X_n)] = \sigma_n^2(\theta),$$

如果样本量 $n \rightarrow \infty$ 时有

$$\lim_{n \rightarrow \infty} \mathbb{P} \left(\frac{\hat{\theta}(X_1, \dots, X_n) - \theta}{\sigma_n(\theta)} \leq x \right) = \Phi(x), \forall x \in \mathbb{R}, \quad (6.10)$$

则称估计量 $\hat{\theta}(X_1, \dots, X_n)$ 有渐近正态性.



根据依分布收敛的定义, 渐近正态性定义6.6也常常记为

$$(\hat{\theta}(X_1, \dots, X_n) - \theta) / \sigma_n(\theta) \xrightarrow{\mathcal{L}} N(0, 1).$$

- 估计量是否具有渐近正态性是其优良性的一个重要标志.
- 渐近正态性提供了估计量的一个近似分布, 利用它我们才能完成相关的统计推断(区间估计和假设检验).
- 在一般条件下, 矩估计和最大似然估计都会有渐近正态性, 例如总体均值 μ 的点估计 $\bar{X}_n$, 由林德伯格-莱维中心极限定理, 我们有

$$\sqrt{n}(\bar{X}_n - \mu)/\sigma \xrightarrow{\mathcal{L}} N(0, 1).$$

例 6.28 设 $X_1, \dots, X_n$ 为来自总体 F 的一组简单随机样本, 设总体 F 期望和方差分别为 μ 和 σ^2 . 则易知样本均值 $\bar{X}$ 和样本方差 S_n^2 分别为 μ 和 σ^2 的相合估计, 且有

$$\sqrt{n}(\bar{X}_n - \mu)/S_n \xrightarrow{\mathcal{L}} N(0, 1).$$




图 6.5: 第六章知识点结构图