

概率论与数理统计

第七章

第七章：区间估计

大纲：

- 基本概念
- 枢轴变量法
- 大样本方法
- 自助法置信区间
- 置信限

7.1 基本概念

对于一个未知量,人们在测量和计算时,常不以得到近似值为满足,还需要估计误差,及要求知道近似值的精确程度 (亦即所求真值所在的范围). 类似的, **对于未知的参数 θ , 除了求出它的点估计 $\hat{\theta}$ 外, 我们还希望估计出一个范围, 并希望知道这个范围包含参数 θ 真值得可信程度.** 这样的范围通常以区间形式给出, 同时还给出此区间包含真值的可信程度. 这种形式的估计称为**区间估计**.

比如你估计月花费支出是 500, 我们相信多少会有误差, 但是误差有多大? 单从你提出的 500 这个数字还给不出什么信息, 若你给出估计支出是 400-600 之间, 则人们相信你在作出这估计时, 已把可能出现的误差考虑到了, 多少给人们以更大的信任感. 因此区间估计也是常用的一种估计方式.

- 设 $X_1, \dots, X_n$ 是从总体 $F_\theta, \theta \in \Theta \subset \mathbb{R}$ 中抽取的一个简单随机样本, 所谓 θ 的区间估计, 就是:

寻找两个统计量 $\hat{\theta}_1(X_1, \dots, X_n) < \hat{\theta}_2(X_1, \dots, X_n)$, 构造区间估计 $[\hat{\theta}_1, \hat{\theta}_2]$, 在获得样本后, 把 θ 估计在区间 $[\hat{\theta}_1, \hat{\theta}_2]$ 中.

- 该区间满足一定要求:

(1) 可靠度要尽可能高, 即概率

$$\mathbb{P}_\theta\left(\hat{\theta}_1(X_1, \dots, X_n) \leq \theta \leq \hat{\theta}_2(X_1, \dots, X_n)\right)$$

要尽可能大, 这意味着我们做出这个推断的可靠程度. 这里 $\mathbb{P}_\theta$ 指在给定参数 θ 下计算概率.

(2) 估计的精度要尽可能高. 由于区间 $[\hat{\theta}_1, \hat{\theta}_2]$ 为随机区间, 因此精度可以用平均区间长度 $\mathbb{E}_\theta[\hat{\theta}_2 - \hat{\theta}_1]$ 来度量. 所以就是要求区间长度尽可能小.

- 可靠度和精度这两个要求是相互矛盾的.
- Neyman 提出了广泛接受的准则: 先保证可靠性, 在此前提下尽可能提高精度.

定义 7.1 置信区间和置信系数

设 $(X_1, \dots, X_n)$ 是从总体中抽取的一个简单随机样本, $\theta \in \Theta \subset \mathbb{R}$ 为未知参数. $\hat{\theta}_1(X_1, \dots, X_n) < \hat{\theta}_2(X_1, \dots, X_n)$ 为两个统计量, 给定一个小的正数 $\alpha \in (0, 1)$, 如果

$$\mathbb{P}_\theta(\hat{\theta}_1(X_1, \dots, X_n) \leq \theta \leq \hat{\theta}_2(X_1, \dots, X_n)) = 1 - \alpha, \quad \forall \theta \in \Theta, \quad (7.1)$$

则称区间 $[\hat{\theta}_1, \hat{\theta}_2]$ 为参数 θ 的置信区间 (Confidence interval) 估计, 置信系数为 $1 - \alpha$. 

- 理解置信系数：
 - θ 是一个未知的常数，没有随机性. 谈不上它落在置信区间的概率是多小
 - 但统计量 $\hat{\theta}_1, \hat{\theta}_2$ 统计量是随机变量，故可看构造的区间估计 $[\hat{\theta}_1, \hat{\theta}_2]$ 有多大的概率罩住未知参数 θ .
 - 设 $\alpha = 0.05$, 从总体中抽取了一个样本, 就可以根据统计量构造一个置信区间, 则独立抽取 100次样本, 就可以构造了 100 个置信区间. 在这 100 个置信区间中, 大约有 95 个能覆盖未知参数 θ , 而有 5 个区间不能覆盖 θ .
- 置信区间仅强调一个区间估计的可靠性要达到指定的要求.
- 在实际中, 达到指定置信系数的置信区间可能有多个
- 区间估计的理论就是在保证置信系数 $(1 - \alpha)$ 下, 去找出有优良精度的区间估计.

7.2 枢轴变量法

枢轴变量法： 设待估参数为 θ ,

1. 找一个 θ 的**良好点估计** $T(\mathbf{X})$, 一般为 θ 的最大似然估计.
2. 构造 T 与 θ 的某一函数 $S(T, \theta, U)$, 称为**枢轴变量**, 使得它的**分布 F 完全已知**. 其中 $U = U(\mathbf{X})$ 为统计量. 枢轴变量仅是 T, θ, U 的函数, 不能包含其他未知参数.
3. 枢轴变量必须满足如下条件: 对 $\forall a < b$ 不等式 $a \leq S(T, \theta, U) \leq b$ 能改写为等价形式 $A \leq \theta \leq B$. 其中 A, B 只能与 **$T(\mathbf{X}), U(\mathbf{X}), a, b$** 有关, **与 θ 无关**.
4. 取分布 F 的**上 $\alpha/2$ 分位数** $w_{\alpha/2}$ 和**上 $(1 - \frac{\alpha}{2})$ 分位数** $w_{1-\alpha/2}$, 有

$$P\left(w_{1-\frac{\alpha}{2}} \leq S(T, \theta, U) \leq w_{\frac{\alpha}{2}}\right) = 1 - \alpha.$$

根据第 3 步, 不等式 $w_{1-\frac{\alpha}{2}} \leq S(T, \theta, U) \leq w_{\frac{\alpha}{2}}$ 可以改写为 $A \leq \theta \leq B$ 的形式, 其中 A, B 是统计量. 则 $[A, B]$ 就是 θ 的置信系数为 $1 - \alpha$ 的置信区间.

设总体分布为 F , 其中 F 连续. 称 w_α 为总体 F 的上 α 分位点, 若

$$F(w_\alpha) = 1 - \alpha.$$

等价地, 总体 F 的下 α 分位点定义为

$$F(v_\alpha) = \alpha,$$

根据定义, 下 α 分位点就是上 $1 - \alpha$ 分位点. 所以 $v_\alpha = w_{1-\alpha}$.




图 7.1: 上分位点

例子（一样本均值）

例 7.2 设 $\mathbf{x} = (x_1, \dots, x_n)$ 是从正态总体 $N(\mu, \sigma^2)$ 中抽取的一个样本, 参数 μ, σ^2 未知, 求 μ 的置信系数为 $1 - \alpha$ 的置信区间.

例 7.3 设某小区的一号楼 1 单元 20 户居民每月煤气和水电的消费服从正态分布 $N(\mu, \sigma^2)$, 本月的平均消费为 160 元, 样本标准差为 20 元, 求居民平均付款额 μ 的置信系数为 95% 的置信区间.

➤ 当样本量 n 很大时, 由中心极限定理, 不论总体是什么分布, 只要二阶矩存在,

则 $\frac{\sqrt{n}(\bar{X}-\mu)}{\hat{\sigma}}$ 近似服从标准正态分布, 这里 $\hat{\sigma}$ 为总体标准差的相合估计.

➤ 关于总体均值 μ 的置信系数为 $1 - \alpha$ 的置信区间近似为

$$\mu \in \bar{x} \pm \frac{\hat{\sigma}}{\sqrt{n}} u_{\alpha/2}$$

总结: 总体均值 μ 的 $1 - \alpha$ 置信区间为 $\bar{x} \pm d$, 其中误差界限 d

$$d = \begin{cases} \frac{\sigma}{\sqrt{n}} u_{\frac{\alpha}{2}}, & \text{总体为正态, } \sigma^2 \text{ 已知} \\ \frac{s}{\sqrt{n}} t_{n-1} \left(\frac{\alpha}{2} \right), & \text{总体为正态, } \sigma^2 \text{ 未知} \\ \frac{\hat{\sigma}}{\sqrt{n}} u_{\alpha/2}, & n > 30, \sigma^2 \text{ 未知, 总体不必正态} \end{cases}$$

例子（一样本方差）

例 7.5 考虑均值方差都未知时正态总体中方差 σ^2 的置信区间估计.

例子（两样本均值）

例 7.6 设有两个独立正态总体, 分别服从 $N(\mu_1, \sigma_1^2)$ 和 $N(\mu_2, \sigma_2^2)$, 其中 σ_1^2, σ_2^2 都已知. 求均值差 $\mu_2 - \mu_1$ 的置信系数为 $1 - \alpha$ 的置信区间. 如果 σ_1^2, σ_2^2 都未知时如何给出置信区间?

解: 设 X, Y 的样本数为 m, n , $\bar{X} \sim N(\mu_1, \frac{\sigma_1^2}{m})$, $\bar{Y} \sim N(\mu_2, \frac{\sigma_2^2}{n})$

➤ 若方差已知, 则枢轴变量及其分布为

$$\frac{(\bar{Y} - \bar{X}) - (\mu_2 - \mu_1)}{\sqrt{\frac{\sigma_1^2}{m} + \frac{\sigma_2^2}{n}}} \sim N(0, 1),$$

因此 $\mu_2 - \mu_1$ 的置信系数为 $1 - \alpha$ 的置信区间为 $\mu_2 - \mu_1 \in (\bar{y} - \bar{x}) \pm \sqrt{\frac{\sigma_1^2}{m} + \frac{\sigma_2^2}{n}} u_{\alpha/2}$

➤ 方差未知时, 若 $\sigma_1^2 = \sigma_2^2 = \sigma^2$, 则有

$$(m+n-2)S_T^2 = \frac{(m-1)S_1^2 + (n-1)S_2^2}{\sigma^2} \sim \chi_{m+n-2}^2$$

则 $\frac{(\bar{Y}-\bar{X})-(\mu_2-\mu_1)}{S_T\sqrt{\frac{1}{m}+\frac{1}{n}}} \sim t_{m+n-2}$, 因此 $\mu_2 - \mu_1$ 的置信系数为 $1 - \alpha$ 的置信区间为

$$\mu_2 - \mu_1 \in (\bar{y} - \bar{x}) \pm s_T \sqrt{\frac{1}{m} + \frac{1}{n}} t_{m+n-2}(\alpha/2)$$

➤ 方差未知时, 若样本量较大($m, n > 30$), 还可以利用中心极限定理得到近似置信区间(提示: 利用样本方差 S_1^2, S_2^2)。此时总体可以不必为正态, σ_1^2, σ_2^2 可以不等。

例子（两样本方差）

- 假设总体 $X \sim N(\mu_1, \sigma_1^2)$, $Y \sim N(\mu_2, \sigma_2^2)$, 样本分别为 $(x_1, \dots, x_m)$, $(y_1, \dots, y_n)$, 均值未知, 求方差比值 σ_1^2/σ_2^2 的区间估计。

解：由F分布的定义，我们有 $\frac{S_1^2/\sigma_1^2}{S_2^2/\sigma_2^2} \sim F_{m-1, n-1}$, 为枢轴变量，因此置信系数为 $1 - \alpha$ 的置信区间为

$$\frac{\sigma_1^2}{\sigma_2^2} \in \left[\left(\frac{S_1^2}{S_2^2} \right) F_{n-1, m-1} \left(1 - \frac{\alpha}{2} \right), \left(\frac{S_1^2}{S_2^2} \right) F_{n-1, m-1} \left(\frac{\alpha}{2} \right) \right]$$