

7.3 大样本方法

- 枢轴变量法中，构造置信区间的关键是要知道枢轴变量的分布.
- 大样本方法就是利用极限定理，特别是中心极限定理，来建立枢轴变量 $S(T(X), \theta, U(X))$ ，使得 $S(T(X), \theta, U(X))$ 的分布与 θ 无关.
 - 一般总体均值 μ 的置信区间
 - 比例 p 的置信区间

一般总体均值 μ 的置信区间

- 设 $(X_1, X_2, \dots, X_n)$ 是从总体 X 中抽取的一个简单随机样本， $E(X) = \mu$ 为感兴趣的参数，同时，总体的分布未知，如何构造 μ 的置信区间？
- 若 $E(X^2) < \infty$ ，根据大数定律，样本标准差 S 是 σ 的一个相合估计。再由中心极限定理，近似有

$$\frac{\sqrt{n}(\bar{X} - \mu)}{S} \sim N(0,1)$$

因此 $\frac{\sqrt{n}(\bar{X} - \mu)}{S}$ 可以作为 μ 近似的枢轴变量，不难得到 μ 的置信水平近似为 $1 - \alpha$ 置信区间为

$$\mu \in \bar{x} \pm \frac{S}{\sqrt{n}} u_{\alpha/2}$$

例 7.9 设 $x_1, \dots, x_n$ 是从 Poisson 总体 $P(\lambda)$ 中抽取的一个简单随机样本, 求 λ 的区间估计.

例 7.10 设 $x_1, \dots, x_n$ 是从指数总体 $Exp(\lambda)$ 中抽取的一个简单随机样本, 求均值 $\theta = \lambda^{-1}$ 的 $1 - \alpha$ 置信区间.

比例 p 的区间估计

- 设事件A在每次试验中发生的概率为 p ，作 n 次独立试验，以 Y_n 记事件A发生的次数，求 p 的 $1 - \alpha$ 置信区间.
- 当 n 充分大时，由中心极限定理，近似有 $\frac{Y_n - np}{\sqrt{np(1-p)}} \sim N(0,1)$ ，因此 $\frac{Y_n - np}{\sqrt{np(1-p)}}$ 可以作为构造 p 的置信区间估计的枢轴变量. 由中心极限定理，得

$$P(-u_{\alpha/2} \leq \frac{Y_n - np}{\sqrt{np(1-p)}} \leq u_{\alpha/2}) \approx 1 - \alpha$$

解不等式 $-u_{\alpha/2} \leq \frac{Y_n - np}{\sqrt{np(1-p)}} \leq u_{\alpha/2}$ ，令 $\hat{p} = y_n/n$ ，我们有置信区间(又称：
得分区间 score interval)

$$p \in \frac{\hat{p} + u_{\alpha/2}^2/(2n)}{1 + u_{\alpha/2}^2/n} \pm u_{\alpha/2} \frac{\sqrt{\hat{p}(1-\hat{p})/n + u_{\alpha/2}^2/(4n^2)}}{1 + u_{\alpha/2}^2/n}, \quad (7.7)$$

令 $\hat{q} = 1 - \hat{p}$, 若要求区间宽度为 w , 则样本量应该满足:

$$n = \frac{u_{\alpha/2}^2 \left[2\hat{p}\hat{q} - w^2 + \sqrt{(2\hat{p}\hat{q})^2 + (1 - 4\hat{p}\hat{q})w^2} \right]}{w^2}$$

例 7.7 网络钓鱼 (phishing) 是一种是通过欺骗性垃圾邮件或者网页, 意图引诱人们给出敏感信息 (如密码, 银行卡号等) 的一种违法攻击方式. 2016 年发表的研究论文* 描述了一项试验, 向 320 名参与者展示一些网页, 并要求他们识别哪些是合法的, 哪些是钓鱼欺诈性的. 在研究的一个阶段, 有 157 名参与者将一个钓鱼网站误认为是安全的. 记 p 为参与试验人数中错误识别钓鱼网站的比例, 求 p 的 95% 置信区间.

解 显然 p 的点估计为 $\hat{p} = 157/320 = .491$, 根据(7.7)知 p 的一个近似 95% 置信区间为

$$\begin{aligned} & \frac{(.491) + (1.96)^2/2(320)}{1 + (1.96)^2/320} \pm 1.96 \frac{\sqrt{(.491)(.509)/320 + (1.96)^2/4(320)^2}}{1 + (1.96)^2/320} \\ & = .491 \pm .054 = (.437, .545). \end{aligned}$$

因此, 在 95% 置信水平下, 我们得出在试验设置下有 43.7% 到 54.5% 之间的参与者不能识别该钓鱼网站.

7.4 自助法置信区间

- 如果总体分布不是正态分布且样本量比较小，如何构建总体参数的置信区间？
- 自助法(Bootstrap method)——仅仅通过使用已有的样本数据而不对总体的分布做任何假设，给出置信区间
 - 将手头的样本当成总体——因为样本在某种意义上反映了总体的信息

标准自助法步骤:

假设我们在当前样本观测值 $x_1, x_2, \dots, x_n$ 下想得到统计量 $\hat{\theta}$ 的自助分布, 则

- (1) 从 $x_1, x_2, \dots, x_n$ 中有放回地抽取一组样本量同样为 n 的样本, 记为 $x_1^*, x_2^*, \dots, x_n^*$, 称为一个自助样本.
- (2) 基于自助样本 $x_1^*, x_2^*, \dots, x_n^*$ 计算统计量 $\hat{\theta}$ 的值, 称为 $\hat{\theta}$ 的一个自助版本.
- (3) 重复上述 (1)-(2) 步足够多次, 比如 B 次, 得到 B 个自助版本 $\hat{\theta}_1^*, \hat{\theta}_2^*, \dots, \hat{\theta}_B^*$, 它们被用来近似统计量 $\hat{\theta}$ 的自助分布. 也就是说视自助版本为 $\hat{\theta}$ 的同分布复制.

基本自助置信区间

构造置信区间的关键： $\hat{\theta} - \theta$ 可以由 $\hat{\theta}^* - \hat{\theta}$ 来近似

定义 7.2 基本自助置信区间

设感兴趣参数 θ 的点估计为 $\hat{\theta}$, 记其 B 个自助版本统计量 $\hat{\theta}_1^*, \hat{\theta}_2^*, \dots, \hat{\theta}_B^*$ 的 $\alpha/2$ 和 $1 - \alpha/2$ 样本分位数分别为 $\hat{\theta}_{[(B+1)\alpha/2]}^*$ 和 $\hat{\theta}_{[(B+1)(1-\alpha/2)]}^*$, 则称

$$\left[2\hat{\theta} - \hat{\theta}_{[(B+1)(1-\alpha/2)]}^*, 2\hat{\theta} - \hat{\theta}_{[(B+1)\alpha/2]}^* \right]$$

为 θ 的 $1 - \alpha$ 基本自助置信区间 (The Basic Bootstrap Confidence Interval).



从小到大排序后

自助t置信区间

若 $\hat{\theta}$ 是 θ 的(渐近)无偏估计, 标准差 $se(\hat{\theta})$ 可以得到, 且枢轴变量 $T = \frac{\hat{\theta} - \theta}{se(\hat{\theta})}$ 的(渐近)分布已知, 则可以用 T 来构造 θ 的置信区间.

未知时, 自助t置信区间法:

1. 使用 $\hat{\theta}$ 的自助版本 $\hat{\theta}_1^*, \hat{\theta}_2^*, \dots, \hat{\theta}_B^*$ 的样本标准差估计 $se(\hat{\theta})$:

$$\widehat{se}_B(\hat{\theta}) = \sqrt{\frac{1}{B-1} \sum_{b=1}^B (\hat{\theta}_b^* - \bar{\hat{\theta}}^*)^2}, \quad \bar{\hat{\theta}}^* = \sum_{b=1}^B \hat{\theta}_b^* / B$$

2. 构建一个“ T 类型”的变量

$$T^* = \frac{\hat{\theta} - \theta}{\widehat{se}_B(\hat{\theta})}$$

3. 再使用自助法计算出 T^* 的样本分位数 $t_{\alpha/2}^*$ 和 $t_{1-\alpha/2}^*$, 从而得到自助t置信区间

定义 7.3 自助 t 置信区间

称

$$[\hat{\theta} - t_{1-\alpha/2}^* \hat{se}_B(\hat{\theta}), \hat{\theta} - t_{\alpha/2}^* \hat{se}_B(\hat{\theta})]$$

为 θ 的 $1 - \alpha$ 自助 t 置信区间 (The Bootstrap t Confidence Interval).



记样本值为 $x = (x_1, \dots, x_n)$, 则自助 t 置信区间的算法如下

1. 由样本观测值得到 $\hat{\theta}$.
2. 对每个再抽样, $b = 1, \dots, B$:
 - (a). 从 x 中有放回的抽样得到第 b 个再抽样样本 $x^{(b)} = (x_1^{(b)}, \dots, x_n^{(b)})$.
 - (b). 由第 b 个再抽样样本计算 $\hat{\theta}_b^*$.
 - (c). 计算 $\hat{\theta}_b^*$ 的标准差估计 $\hat{se}_R(\hat{\theta}_b^*)$. (即对每个再抽样样本 $x^{(b)}$, 生成 R 个自助版本为 $\tilde{\theta}^*$, 使用自助法估计标准差):

$$\hat{se}_R(\hat{\theta}_b^*) = \sqrt{\frac{1}{R-1} \sum_{k=1}^R (\tilde{\theta}_k^* - \overline{\tilde{\theta}^*})^2}, \quad (7.17)$$

其中 $\overline{\tilde{\theta}^*} = \sum_b \tilde{\theta}_b^* / R$. 注意此步嵌套使用了自助法.

- (d). 计算第 b 个重复下的“ t ”统计量: $t^{(b)} = (\hat{\theta}_b^* - \hat{\theta}) / \hat{se}_R(\hat{\theta}_b^*)$
3. 重复样本 $t^{(1)}, \dots, t^{(B)}$ 的分布作为推断分布. 找出样本分位数 $t_{\alpha/2}^*$ 和 $t_{1-\alpha/2}^*$.
4. 计算 $\hat{se}_B(\hat{\theta})$, 即自助版本 $\{\hat{\theta}_b^*\}$ 的样本标准差.
5. 计算置信界 $[\hat{\theta} - t_{1-\alpha/2}^* \hat{se}_B(\hat{\theta}), \hat{\theta} - t_{\alpha/2}^* \hat{se}_B(\hat{\theta})]$

7.5 置信限

在实际问题中，有时候我们只对参数 θ 一侧的界限感兴趣：

- 对某种药品的毒性，我们希望它越小越好，因此我们关心的置信上限 $\bar{\theta}$ ($\theta \leq \bar{\theta}$ 概率大)
- 对手机的平均寿命而言，我们希望它越大越好，因此我们关心的是置信下限 $\underline{\theta}$ ($\theta \geq \underline{\theta}$ 概率大)

定义7.4

设 $(X_1, X_2, \dots, X_n)$ 是从总体 $F(x, \theta)$ 中抽取的一个简单随机样本, $\bar{\theta} = \bar{\theta}(X_1, X_2, \dots, X_n)$, $\underline{\theta} = \underline{\theta}(X_1, X_2, \dots, X_n)$ 为两个统计量.

1. 若对 θ 的一切可取的值, 有

$$P(\bar{\theta}(X_1, X_2, \dots, X_n) \geq \theta) = 1 - \alpha \quad (7.18)$$

则称 $\bar{\theta}$ 为 θ 的一个置信系数为 $1 - \alpha$ 的置信上限;

2. 若对 θ 的一切可取的值, 有

$$P(\underline{\theta}(X_1, X_2, \dots, X_n) \leq \theta) = 1 - \alpha \quad (7.19)$$

则称 $\underline{\theta}$ 为 θ 的一个置信系数为 $1 - \alpha$ 的置信下限;

- 置信上限和置信下限是一种特殊的置信区间，其一端为 ∞ 或 $-\infty$. 寻求置信上限的方法和寻求置信区间的方法完全类似。
- $(-\infty, \bar{\theta}]$ 和 $[\underline{\theta}, +\infty)$ 都称为是单边的置信区间.
- 例如：求正态分布总体 $N(\mu, \sigma^2)$ 的均值 μ 的置信限.
 - 当 σ^2 已知时， $\sqrt{n}(\bar{X} - \mu)/\sigma$ 是枢轴变量，分布为标准正态，故

$$P\left(\frac{\sqrt{n}(\bar{X} - \mu)}{\sigma} \geq -u_{\alpha}\right) = 1 - \alpha \Rightarrow P\left(\bar{X} + \frac{\sigma}{\sqrt{n}}u_{\alpha} \geq \mu\right) = 1 - \alpha$$

即： $\bar{x} + \frac{\sigma}{\sqrt{n}}u_{\alpha}$ 是 μ 的 $1 - \alpha$ 的置信上限.

同理， μ 的 $1 - \alpha$ 的置信下限为 $\bar{x} - \frac{\sigma}{\sqrt{n}}u_{\alpha}$.

➤ 当 σ^2 未知时, μ 的 $1 - \alpha$ 的置信上限和置信下限分别为 $\bar{x} + \frac{s}{\sqrt{n}} t_{n-1}(\alpha)$ 和 $\bar{x} -$

$$\frac{s}{\sqrt{n}} t_{n-1}(\alpha)$$

- **例如:** 正态分布总体 $N(\mu, \sigma^2)$ 中, μ 未知时, σ^2 的 $1 - \alpha$ 的置信上限和置信下限分别为 $(n - 1)s^2 / \chi_{n-1}^2(1 - \alpha)$ 和 $(n - 1)s^2 / \chi_{n-1}^2(\alpha)$

例 7.13 设某地区 12 个测量点测得某时刻空气质量指数 (Air Quality Index, AQI)($\mu g/m^3$) 为

29, 37, 47, 57, 53, 60, 54, 51, 46, 44, 33, 32.

设空气质量指数服从正态分布, 求该时刻某地区空气质量指数的 90% 的置信上限. 能否说该时刻某地区的空气为优? (空气质量指数在 $50\mu g/m^3$ 以下为优)




图 7.7: 第七章知识点结构图