


概率论与数理统计

第九章：

非参数假设检验

9.1 拟合优度检验



- 判断总体是否来自于某种类型的分布。
- 如检验 H_0 : 总体 X 服从某种理论分布 F 。收集样本来拟合。
- 样本对于原假设的总体分布“拟合”较好：不拒绝原假设。
反之拒绝原假设。 — 拟合优度检验 (goodness of fit test)

9.1.1 理论总体分布完全已知且只取有限个值

- 设总体 X 服从一个离散分布 F , 取有限个值 $\{a_1, \dots, a_k\}$ 已知且两两不同, $p_1 \cdots p_k$ 完全已知.

X	a_1	$\dots$	a_k
P	p_1	$\dots$	p_k

- 现从该总体抽得一个样本量为 n 的简单随机样本, 其落在类别 $a_1, \dots, a_k$ 的观测数分别为 $n_1, \dots, n_k$. $\sum_{i=1}^k n_i = n$.
- 问总体 X 的分布律是否为 $P(X = a_i) = p_i, i = 1, \dots, k$?
- 检验问题:

$$H_0: P(X = a_i) = p_i, i = 1, \dots, k \leftrightarrow H_1: \exists j \text{ s.t. } P(X = a_j) \neq p_j.$$

类别	a_1	a_2	$\cdots$	a_i	$\cdots$	a_k
理论值(E)	np_1	np_2	$\cdots$	np_i	$\cdots$	np_k
观测值(O)	n_1	n_2	$\cdots$	n_i	$\cdots$	n_k
$np_i - n_i$	$np_1 - n_1$	$np_2 - n_2$	$\cdots$	$np_i - n_i$	$\cdots$	$np_k - n_k$

- 大数定律：在 H_0 下， $\frac{n_i}{n} \xrightarrow{P} p_i$.
- 检验的想法：最后一行的值越小，则 H_0 越像是正确的 — 用差值来构造统计量。

Pearson 提出检验统计量：

$$Z = \sum \frac{(O - E)^2}{E} = \sum_{i=1}^k \frac{(np_i - n_i)^2}{np_i} = \sum_{i=1}^k \frac{n_i^2}{np_i} - n,$$

定理 9.1 *Pearson* - χ^2 检验

如果原假设 H_0 成立, 则当样本量 $n \rightarrow \infty$ 时, Z 的分布趋于自由度为 $k-1$ 的 χ^2 分布, 即 χ_{k-1}^2 .



- 检验 φ 为: $Z > \chi_{k-1}^2(\alpha)$ 时拒绝 H_0 , 否则不能拒绝 H_0 .

- 假定根据一组数据算得 $Z = Z_0$: 如果原假设成立, 出现像 Z_0 这样大的差异或更大差异的概率有多大?
- 近似地, 我们有 p 值: $p(Z_0) = P_{H_0}(Z \geq Z_0) = 1 - F_{\chi^2_{k-1}}(Z_0)$
- $p(Z_0)$ 越大, 说明在 H_0 成立时, 出现 Z_0 这样大的差异就越不奇怪, 从而就越使人们相信原假设的正确性
 - ✓ 故: $p(Z_0)$ 可解释为对理论分布的“拟合优度”.
- 因此检验 φ 等价于: $p(Z_0) < \alpha$ 时, 拒绝原假设.

例 9.1 在一个三班制生产的工厂中, 本月出了 30 次事故, 其中早、中、晚班事故数分别为 12, 6, 12 次. 问事故与班次是否有关?

9.1.2 理论分布类型已知但含有有限个未知参数

- 设总体 X 服从一个离散分布, 取有限个值 $\{a_1, \dots, a_k\}$ 已知且两两不同,
 $p_i = p_i(\theta_1, \dots, \theta_r)$, $i = 1 \dots k$ 依赖于 r 个未知参数 $\theta_1, \dots, \theta_r$, $r < k - 1$.

X	a_1	$\dots$	a_k
P	p_1	$\dots$	p_k

- 检验问题 $H'_0: P(X = a_i) = p_i(\theta_1, \dots, \theta_r)$, $i = 1, \dots, k$.
- 样本为 $(X_1, \dots, X_n)$. n_i 为样本取 a_i 的次数, $i = 1, \dots, k$.
- 检验统计量:

$$Z = \sum \frac{(O - \hat{E})^2}{\hat{E}} = \sum_{i=1}^k \frac{(n_i - n\hat{p}_i)^2}{n\hat{p}_i} = \sum_{i=1}^k \frac{n_i^2}{n\hat{p}_i} - n$$

- 在原假设下, $\hat{\theta}_1, \dots, \hat{\theta}_r$ 为 $\theta_1, \dots, \theta_r$ 的最大似然估计, 从而 p_i 的最大似然估计为 $\hat{p}_i = p_i(\hat{\theta}_1, \dots, \hat{\theta}_r), i = 1, \dots, k$.

定理 9.2

在一定的条件下, 若原假设 H'_0 成立, 则当 $n \rightarrow \infty$ 时, Z 的分布趋于自由度为 $k - r - 1$ 的 χ^2 分布, 即 χ^2_{k-r-1} .



估计的独立参数个数

- 检验为: ϕ' : 当 $Z > \chi^2_{k-r-1}(\alpha)$ 时, 拒绝 H'_0 , 否则不能拒绝 H'_0
- 或 p 值 $< \alpha$ 时, 拒绝 H'_0

例 9.4 从某人群中随机抽取 100 个人的血液, 并测定他们在某基因位点处的基因型. 假设该位点只有两个等位基因 A 和 a, 这 100 个基因型中 AA, Aa 和 aa 的个数分别为 30, 40, 30, 则能否在 0.05 的水平下认为该群体在此位点处达到 Hardy-Weinberg 平衡态?

- 设人群中等位基因A的概率为 p , 则该人群在此位点处达到Hardy-Weinberg平衡态指的是在人群中3个基因型的概率分别为

$$P(AA) = p^2, \quad P(Aa) = 2p(1 - p), \quad P(aa) = (1 - p)^2.$$

H_0

总体 X 有无穷多个取值但分布仅含有有限个未知参数

- 检验问题: $H_0'': X \sim F_\theta(x)$, $x \in R$. 其中 $\theta = (\theta_1, \dots, \theta_r)$ 为未知参数.
- 例如: $X \sim N(\mu, \sigma^2)$, 但参数 μ, σ^2 未知.
- 检验方法—离散化:

✓ 将总体的取值分割为 k 段:

$$(x_0, x_1], \dots, (x_{k-2}, x_{k-1}], (x_{k-1}, x_k). \quad x_0 = -\infty, \quad x_k = \infty.$$

✓ 定义离散型随机变量:

$$Y = a_i, \quad x_{i-1} < X \leq x_i, \quad i = 1, \dots, k.$$

✓ 原假设 H_0'' 成立时, Y 的分布为:

$$P(Y = a_i) = p_i(\theta_1, \dots, \theta_r) = F_\theta(x_i) - F_\theta(x_{i-1})$$

✓ 转换(非等价)为 H_0' 的检验问题.

- 离散化方法依赖于对总体 X 取值范围的划分
 - ✓ 划分的区间一般使得理论频数 $np_i \geq 5, i = 1, \dots, k$, 若不满足, 最好把某些组合并。
 - ✓ 划分点不依赖于样本, 事先定好。

- 从某连续总体中抽取一个样本量为100的样本，发现样本均值和样本标准差分别为 -0.225 和 1.282 ，落在不同区间的频数如下表所示：

区间	$(-\infty, -1)$	$[-1, -0.5)$	$[-0.5, 0)$	$[0, 0.5)$	$[0.5, 1)$	$[1, \infty)$
观测频数	25	10	18	24	10	13

可否在显著性水平0.05下认为该总体服从正态分布？

区间	$(-\infty, -1)$	$[-1, -0.5)$	$[-0.5, 0)$	$[0, 0.5)$	$[0.5, 1)$	$[1, \infty)$
观测频数	25	10	18	24	10	13
理论频数	27	14	16	14	12	17

9.1.3 列联表检验

- 理论分布类型已知，但有若干个参数未知的检验常用于列联表检验。
- 列联表**(contingency table): 一种按两个属性作双向分类的表
 - ✓ 例: 一群人按照吸烟和不吸烟(属性 A)和是否患肺癌(属性 B)分类。
 - ✓ 记属性 A 有 a 个不同水平, 属性 B 有 b 个不同水平, 将 n 个观测样本按照属性 A 和属性 B 所处的水平进行汇总, 得到一个 $a \times b$ 列联表:

表 9.3: $a \times b$ 列联表

✓ $n_{i\cdot} = \sum_{j=1}^b n_{ij}$

---属性 A 处于水平 i 的个体数.

✓ $n_{\cdot j} = \sum_{i=1}^a n_{ij}$

---属性 B 处于水平 j 的个体数.

$B \backslash A$							和
	1	2	...	i	...	a	
1	n_{11}	n_{21}	...	n_{i1}	...	n_{a1}	$n_{\cdot 1}$
2	n_{12}	n_{22}	...	n_{i2}	...	n_{a2}	$n_{\cdot 2}$
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$
j	n_{1j}	n_{2j}	...	n_{ij}	...	n_{aj}	$n_{\cdot j}$
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$
b	n_{1b}	n_{2b}	...	n_{ib}	...	n_{ab}	$n_{\cdot b}$
和	$n_{1\cdot}$	$n_{2\cdot}$	...	$n_{i\cdot}$	...	$n_{a\cdot}$	n

- 目的: H_0 : 属性A和属性B独立
- 令 X : 属性A的水平, $X = 1, \dots, a$.

Y : 属性B的水平, $Y = 1, \dots, b$.

$$p_{ij} = P(X = i, Y = j) = P(\text{属性A, B分别处于水平 } i, j).$$

$$p_{i\cdot} = P(X = i) = P(\text{属性A处于水平 } i). \quad \sum_{i=1}^a p_{i\cdot} = 1.$$

$$p_{\cdot j} = P(Y = j) = P(\text{属性B处于水平 } j). \quad \sum_{j=1}^b p_{\cdot j} = 1.$$

- H_0 等价于 $H_0: p_{ij} = p_{i\cdot}p_{\cdot j}, \quad \forall 1 \leq i \leq a, 1 \leq j \leq b.$

- 回忆：统计量 $Z = \sum \frac{(O-E)^2}{E} = \sum_{i=1}^a \sum_{j=1}^b \frac{(n_{ij} - np_{ij})^2}{np_{ij}} \xrightarrow{H_0}$
 $= \sum_{i=1}^a \sum_{j=1}^b \frac{(n_{ij} - np_{i \cdot p \cdot j})^2}{np_{i \cdot p \cdot j}} \xrightarrow{\text{估计}} \sum_{i=1}^a \sum_{j=1}^b \frac{(n_{ij} - n\hat{p}_{i \cdot} \hat{p}_{\cdot j})^2}{n\hat{p}_{i \cdot} \hat{p}_{\cdot j}}$

- 最大似然估计法: $\hat{p}_{i \cdot} = \frac{n_{i \cdot}}{n}, \hat{p}_{\cdot j} = \frac{n_{\cdot j}}{n}.$

- 独立参数的个数: $r = (a - 1) + (b - 1) = a + b - 2$

- 统计量Z为 $Z = \sum_{i=1}^a \sum_{j=1}^b \frac{(n_{ij} - n_{i \cdot} n_{\cdot j} / n)^2}{n_{i \cdot} n_{\cdot j} / n}$
 $= \sum_{i=1}^a \sum_{j=1}^b \frac{(nn_{ij} - n_{i \cdot} n_{\cdot j})^2}{nn_{i \cdot} n_{\cdot j}}.$

当 $n \rightarrow \infty$ 时, Z 的渐近分布是自由度为 $k - 1 - r = ab - 1 - (a + b - 2) = (a - 1)(b - 1)$ 的 χ^2 分布, 即 $\chi_{(a-1)(b-1)}^2$.

例 9.7 为了了解吸烟是否与患肺癌有关, 在 6000 人中作了调查, 数据如下:

	不吸烟	吸烟	$n_{i.}$
无肺癌	3397	2585	5982
患肺癌	3	15	18
$n_{.j}$	3400	2600	6000

四格表, 自由度为1, χ_1^2

问根据以上数据, 吸烟是否与患肺癌有关? ($\alpha = 0.001$)

理论值

H_0 : 吸烟与患肺癌无关。

拒绝 H_0 .

	不吸烟	吸烟	$n_{i.}$
无肺癌	3397(3389.8)	2585(2592.2)	5982
患肺癌	3(10.2)	15(7.8)	18
$n_{.j}$	3400	2600	6000

例 9.8 据报道, 不同时代出生的人在请朋友吃饭时的人均消费是不同的, 大体上是 60 岁以上倾向于人均低一点的消费. 为了证实这一报道是否正确, 某机构作了如下一个关于请朋友吃饭人均消费 (元) 的调查:

人均消费 年龄段						$n_{i.}$
	[50,80)	[80,120)	[120,150)	[150,200)	≥ 200	
(25,45]	11	26	35	20	9	101
(45,60]	21	35	50	30	5	141
>60	20	38	30	15	1	104
$n_{.j}$	52	99	115	65	15	346

问报道的消息是否正确? ($\alpha = 0.05$)

H_0 : 不同时代出生的人在请朋友吃饭时人均消费没有差异。

理论值

拒绝 H_0

$$\chi^2_{(5-1)(3-1)}$$

理论频数在分母上，其值过小时容易造成误判。

理论频数不小于5为宜，合并不满足条件的列或行。

人均消费 年龄段	[50,80)	[80,120)	[120,150)	[150,200)	≥ 200	$n_{i.}$
(25,45]	11(15.2)	26(28.9)	35(33.6)	20(19.0)	9(4.4)	101
(45,60]	21(21.2)	35(40.3)	50(46.9)	30(26.5)	5(6.1)	141
>60	20(15.6)	38(29.8)	30(34.6)	15(19.5)	1(4.5)	104
$n_{.j}$	52	99	115	65	15	346

人均消费 年龄段	[50,80)	[80,120)	[120,150)	≥ 150	$n_{i.}$
(25,45]	11(15.2)	26(28.9)	35(33.6)	29(23.4)	101
(45,60]	21(21.2)	35(40.3)	50(46.9)	35(32.6)	141
>60	20(15.6)	38(29.8)	30(34.6)	16(24)	104
$n_{.j}$	52	99	115	80	346

不拒绝 H_0

$$\chi^2_{(4-1)(3-1)}$$

注 跟列联表有关的另一类重要的检验是齐一性检验, 即检验某一个属性 A 的各个水平对应的另一个属 B 的分布全部相同:

$$H_0 : \mathbb{P}(B = j|A = 1) = \mathbb{P}(B = j|A = 2) = \cdots = \mathbb{P}(B = j|A = a), j = 1, \dots, b.$$

此时不同于前面讨论的 χ^2 检验中, 属性 A 的各个水平的频数 $n_{i\cdot}, i = 1, \dots, a$ 都是随机的 (试验前不知道取值), 在齐一性检验问题中, 它们在试验前就已经给定. 例如有三个工厂生产同一种产品, 产品分为 1、2、3 等品, 为了考察该工厂产品质量是否一致, 分别从这三个工厂中抽取了 100, 89 和 92 件产品, 并检验了每件产品的等级, 这里 $n_1 = 100, n_2 = 89, n_3 = 92$ 是在抽取前就已经已知的, 不同于列联表中随机的 $n_{i\cdot}, i = 1, 2, 3$. 对齐一性检验问题, 理论上可以证明, 所构造的检验统计量 Z 的极限分布仍是自由度为 $(a-1)(b-1)$ 的 χ^2 分布, 即视属性 A 为随机的, 所采用的检验方法跟独立性检验完全一样. 齐一性检验本质是把三个工厂产品的分布视为 3 个总体, 检验的假设是 “这三个总体的分布一致 (齐一)”. 而列联表检验的是两个属性是否有关联.